

# Visualize and Reinforce

1<sup>st</sup> Gustavo Sanches Costa

*Escola de Matemática Aplicada - EMAP*  
*Fundação Getúlio Vargas - FGV*  
Rio de Janeiro, Brazil  
gsanchescosta@yahoo.com.br

Lucas Bryan Treuke

*Escola de Matemática Aplicada - EMAP*  
*Fundação Getúlio Vargas - FGV*  
Rio de Janeiro, Brazil  
lucasbryantreuke@gmail.com

Rodrigo Gomes Hutz Pintucci

*Escola de Matemática Aplicada - EMAP*  
*Fundação Getúlio Vargas - FGV*  
Rio de Janeiro, Brazil  
rodrigogh@gmail.com

**Abstract**—Este artigo apresenta o processo de concepção de um site explicativo que utiliza técnicas de visualização para auxiliar estudantes e entusiastas na compreensão de conteúdos complexos relacionados ao aprendizado por reforço e métodos de aprendizado de máquinas. O objetivo é reduzir a lacuna entre o conhecimento teórico e prático, fornecendo uma abordagem clara e acessível. O estudo propõe o uso do algoritmo de pseudo-rotulagem em conjunto com o aprendizado por reforço para mapear as espécies de árvores em uma floresta densa. O algoritmo de pseudo-rotulagem é eficiente na classificação de conjuntos de dados com poucas anotações. O aprendizado por reforço é utilizado no processo de escolha dos dados para categorização e treinamento do modelo. O objetivo é selecionar dados representativos que melhor explicam a distribuição de cada classe.

**Index Terms**—Pseudo-rotulagem, interação, visualização, aprendizado

## I. INTRODUÇÃO

Entender assuntos complicados pode ser uma tarefa desafiadora, especialmente para aqueles que estão sendo introduzidos a um tema pela primeira vez. Nas áreas computacionais e matemáticas, essa dificuldade se torna ainda mais aparente, uma vez que o conhecimento é construído de forma hierárquica, exigindo uma base sólida. Na ciência de dados, não é diferente: aprender conceitos de aprendizado de máquina, modelagem matemática, estatística, entre outros, são pré-requisitos para avançar nesse campo. Portanto, torna-se cada vez mais crucial reduzir a lacuna entre o conhecimento teórico e o conhecimento prático.

Uma abordagem poderosa para facilitar o processo de aprendizagem e aprimorar a compreensão é o uso de técnicas de visualização. A visualização tem se mostrado uma ferramenta valiosa em diversos domínios, auxiliando na compreensão de conceitos complexos, simplificando informações e promovendo uma compreensão intuitiva. Ao aproveitar o sentido visual, os estudantes podem superar as barreiras impostas por representações abstratas e se envolver com o material de forma mais efetiva.

Neste artigo, nosso principal objetivo é apresentar o processo de concepção de um site explicativo sobre conteúdos de aprendizado por reforço e métodos de aprendizado de máquinas, com foco em explicações baseadas em visualização. Através deste site, buscamos fornecer uma abordagem clara e acessível para auxiliar estudantes e entusiastas na compreensão desses temas complexos. Acreditamos que a visualização

interativa desempenha um papel fundamental nesse processo, permitindo que os usuários observem os conceitos em ação, compreendam o funcionamento dos algoritmos e visualizem os resultados obtidos.

Com relação ao algoritmo desenvolvido, o objetivo é mapear as espécies de árvores em uma floresta densa partindo apenas das imagens de suas copas e de um escasso conhecimento a priori dessas classificações. No contexto do estudo em questão, a proporção de árvores das quais possuímos conhecimento das espécies e daquelas das quais não possuímos é bastante reduzida, uma proporção de cerca de 0.1. Com base nessa premissa, propomos a aplicação do algoritmo de pseudo-rotulagem em conjunto com o Aprendizado por Reforço.

De acordo com Liu (2021) [1], o algoritmo de pseudo-rotulagem tem sido amplamente adotado devido à sua eficiência e utilidade na classificação de conjuntos de dados com poucas anotações. O algoritmo opera da seguinte maneira: em primeiro lugar, um modelo de classificação é treinado utilizando os poucos dados que possuem rótulos; em seguida, são selecionados e categorizados os dados do conjunto que não possuem rótulos; por fim, os dados selecionados são utilizados em conjunto com os dados originalmente rotulados para re-treinar o classificador na etapa inicial.

O Aprendizado por reforço será utilizado como parte do processo de escolha de quais dados devem ser categorizados e quais entrarão para o conjunto de treinamento. A meta dessa parte é tentar escolher apenas dados que são mais representativos e que expliquem melhor a distribuição de cada classe.

## II. TRABALHOS RELACIONADOS

A utilização de visualização e mecanismos ilustrativos tem sido amplamente explorada para facilitar o processo de aprendizagem de conteúdos complexos. Nesta seção, realizaremos uma revisão das principais fontes de inspiração para o presente trabalho, tanto na área de visualização quanto no campo de aprendizado de máquina, a fim de contextualizar nossa pesquisa no estado-da-arte e identificar lacunas que justifiquem a relevância da nossa abordagem.

Um dos principais artigos que serviu de inspiração para este estudo foi o trabalho de Deisenroth et al. (2020) sobre Processos Gaussianos [4], disponível no link: <https://infallible-thompson-49de36.netlify.app>. Nesse artigo, os autores detalham minuciosamente o assunto, explicando os componentes

individuais, revisando a matemática envolvida e discutindo as interpretações dos parâmetros. A apresentação desse conteúdo com um nível mais abstrato permite aos leitores uma compreensão mais abrangente dos diversos aspectos e detalhes que muitas vezes passam despercebidos ao ler apenas o conteúdo técnico. Esse trabalho visou tornar a temática mais acessível e interpretável, oferecendo uma abordagem que facilita a compreensão do assunto.

Em termos de estrutura, nosso artigo é amplamente fundamentado nos trabalhos encontrados no site distill.com, com destaque para o artigo de Hilton et al., intitulado "Understanding RL Vision", publicado no Distill em 2020 [2]. Nesse artigo, diversas técnicas de storytelling são empregadas para construir o conhecimento sobre aprendizado por reforço.

No contexto do tema de pseudo-rotulagem e aprendizado por reforço, foram utilizados três artigos como referência. O primeiro deles é o estudo realizado por Rosa (2021) [3], no qual imagens hiperespectrais são combinadas com uma rede neural convolucional para identificar as copas das árvores e construir uma base de dados contendo características específicas de cada árvore, com um total de 14 classes de árvores anotadas. Neste trabalho, optamos por simular os dados, com o objetivo de avaliar a eficácia do método em um ambiente totalmente controlado.

O segundo é um descritor do método de pseudo-rotulagem, em Bonilla (2020) [5] foi feita uma explicação detalhada do método e dos motivos pelos quais acompanha o estado da arte no que se diz a aprendizado de máquinas.

E no terceiro, Liu(2021) [1] explica como utilizou de Aprendizado por reforço como um algoritmo de tomada de decisão para incluir labels ou não, substituindo a análise de currículo implementada em Bonilla (2020).

### III. MÉTODOS

Nesta seção, descreveremos os métodos utilizados e sua importância para o trabalho final.

#### A. Storytelling

O storytelling proporciona uma estrutura coerente para a apresentação dos conteúdos, permitindo que os aprendizes acompanhem uma sequência lógica e compreendam a relação entre os diferentes elementos do aprendizado de máquina. Isso facilita a assimilação dos conceitos e auxilia na construção de uma compreensão sólida dos princípios fundamentais.

Uma vantagem adicional do storytelling é a capacidade de transmitir não apenas informações técnicas, mas também o contexto e a importância do aprendizado de máquina na vida real. Ao apresentar casos de uso relevantes, tornamos o assunto mais tangível e motivador. Em nosso artigo, utilizamos o exemplo da classificação de árvores com base na copa, pois é um problema real que requer a aplicação dos métodos escolhidos na prática.

#### B. Splash image

Outro método utilizado é inspirado no mundo dos quadrinhos de super-heróis: a splash image/panel consiste em uma

imagem maior, geralmente com mais informações do que as outras imagens, que tem a função de instigar a curiosidade do leitor.

Para isso, criamos um gráfico que representa a visualização aérea de uma floresta, na qual a maioria das árvores ainda não está classificada quanto à espécie. Além disso, incluímos uma barra que percorre as iterações do algoritmo e classifica gradualmente as árvores. Ao final da animação, temos uma "floresta" totalmente classificada.

É importante observar que, inicialmente, não fornecemos explicações sobre o que está sendo feito ou como está sendo feito. No entanto, o usuário pode interagir com o gráfico por meio de tooltips e com a própria barra que percorre as iterações, o que permite supor o que está acontecendo.

#### C. Animação

A página é completamente projetada com base em animações, impulsionada por dois fatores principais. Primeiramente, o algoritmo adotado funciona de maneira iterativa, executando iterações sucessivas, conhecidas como "épocas", para aprimorar a precisão e o desempenho. Por meio da animação, é possível visualizar claramente o progresso do algoritmo a cada iteração, proporcionando uma compreensão visual do processo passo a passo. Além disso, a animação desempenha um papel fundamental em manter o interesse e o envolvimento do leitor, tornando a experiência mais cativante e estimulante.

#### D. Ferramentas

Para criar as visualizações, foram utilizadas tanto a linguagem Python quanto a biblioteca JavaScript chamada D3. O Python foi empregado na construção do modelo de pseudo-rotulagem e no processo de amostragem, enquanto o D3 foi utilizado para gerar gráficos com base nos dados produzidos pelo script em Python.

### IV. RESULTADOS

Nesta seção, apresentamos os resultados obtidos a partir da criação da página explicativa e dos experimentos realizados com estudantes da EMAP - FGV (Escola de Matemática Aplicada da FGV). Descreveremos em detalhes esses experimentos, justificando as escolhas de marcas visuais, codificações e design adotadas.




Fig. 1. Splash image

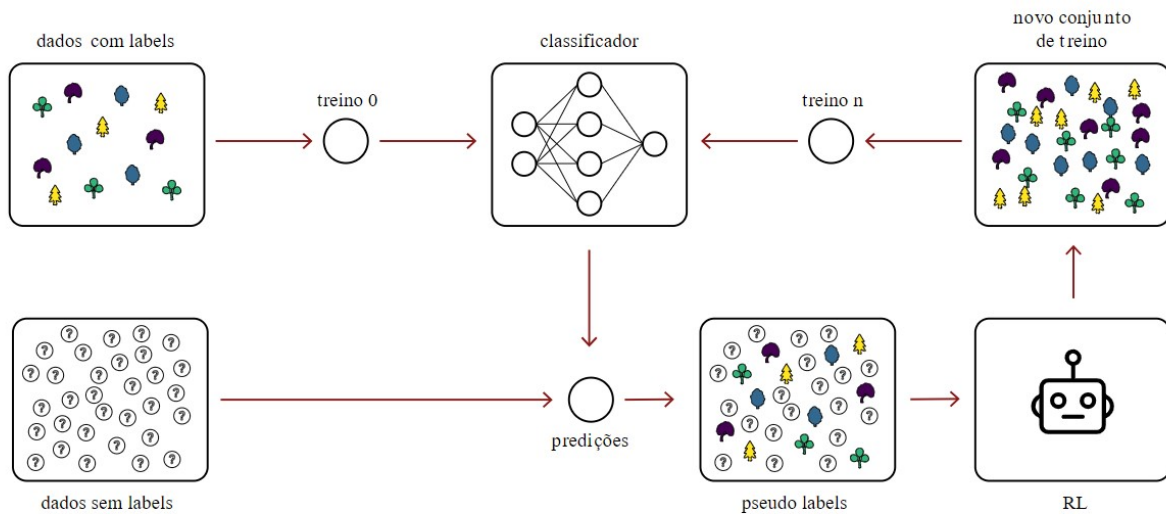


Fig. 2. Fluxograma do algoritmo

A primeira visualização (figura 1) implementada na página é a splash image. Optamos por um gráfico de dispersão que representa a distribuição das copas das árvores em uma floresta vista de cima. Para isso, foram utilizados elementos SVG que remetsem a árvores para utilizar como forma do ponto, para reforçar a ideia de que são espécies completamente distintas. Além disso, de forma redundante, também foi alterada a cor dessas marcas visuais comunicar a diferença de classe de forma ainda mais eficiente.

Em conjunto com a capacidade de alternar entre as iterações do algoritmo usando um controle deslizante, o gráfico inicialmente causa confusão, levantando perguntas como "o que está acontecendo com os pontos não classificados?" e "como eles estão sendo classificados?". Isso instiga o leitor a continuar a explorar o artigo.

Além disso, implementamos a funcionalidade de filtragem dos pontos, permitindo que o usuário selecione pontos específicos ao pressionar as marcas visuais correspondentes na legenda ao lado do gráfico.

A figura 2 na página desempenha um papel fundamental ao fornecer uma visão geral do artigo e do método utilizado, seguindo a abordagem de Schneiderman (1996) [6] de introduzir uma visualização com um panorama geral. Essa estratégia visa manter o usuário envolvido após a splash image, oferecendo uma compreensão antecipada do conteúdo subsequente e mantendo a transparência da página.

Para atingir esse objetivo, foi criado um fluxograma interativo do algoritmo, com o intuito de aprimorar a capacidade de compreensão do leitor. A interatividade é incorporada por meio de tooltips, que fornecem um breve resumo das etapas específicas do algoritmo ao passar o mouse sobre cada uma delas. Essa abordagem permite que o usuário tenha uma visão geral clara do processo em andamento, facilitando a compreensão dos padrões, a análise dos dados e a apreensão do contexto.

A figura 3 também apresenta um gráfico de dispersão, porém, desta vez, localizado no espaço dos parâmetros. Seu principal propósito é esclarecer o critério de decisão das classes, revelando padrões visuais específicos. No caso do nosso conjunto de dados, o padrão identificado assume a forma de um "X". Ao ler o texto correspondente, o leitor é capaz de deduzir que esse padrão surge devido à característica do algoritmo de selecionar apenas os pontos que são considerados "fáceis" de serem classificados. Em outras palavras, são pontos que apresentam alta probabilidade de pertencerem a uma determinada espécie.



Fig. 3. Visualização Pseudo-rotulagem

Na figura 4, consiste na demonstração dos resultados alcançados pelo algoritmo, mostrando a efetividade de sua classificação para o conjunto de dados em questão. Optou-se por utilizar uma matriz de confusão, devido à sua ampla

utilização na comunidade de aprendizado de máquina como uma representação gráfica comumente empregada para avaliar o desempenho de modelos de classificação.

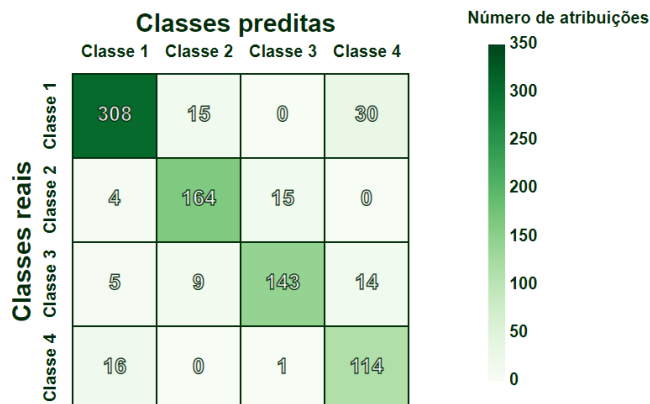


Fig. 4. Matriz de confusão

A última visualização, foi feita com o objetivo de capacitar o usuário pouco experiente a entender normais multivariadas e como os dados foram gerados após a abstração dos dados reais. Nela, é possível alterar os parâmetros da distribuição em ambos os eixos movendo o círculo posicionado no topo da curva gaussiana. Existe também um botão na página do artigo, que altera a amostragem feita no gráfico, com a finalidade de dar a intuição de que as amostras irão estar em uma região definida pela função.




Fig. 5. Amostragem interativa

Além disso, para complementar os resultados, realizou-se um experimento envolvendo alunos do curso de matemática

aplicada da EMap - FGV. Esses alunos possuíam algum conhecimento prévio sobre o tema da classificação e certa familiaridade com modelos matemáticos. Foi solicitado a eles que lessem o artigo e, caso tivessem compreendido, que explicassem o conteúdo abordado. Dois alunos foram selecionados para participar do experimento, e ambos foram capazes de explicar adequadamente o tema. Embora esse experimento tenha sido conduzido em uma escala bastante reduzida, ele indica que, mesmo sendo um assunto complexo, as informações foram transmitidas de maneira eficaz por meio dos textos e das imagens presentes no artigo.

## V. DISCUSSÃO

É esperado que o usuário que utilize visualizações possa entender melhor o tema do trabalho e até as suas bases necessárias, nesse sentido, acredita-se que as interações e as visualizações feitas desempenham um papel fundamental nessa tarefa.

A figura 2 permite o visualizador a entender rapidamente o processo geral, aumentando a capacidade de entender os detalhes da implementação ao ler o texto futuramente, além disso, as visualização 3 evidencia a principal característica do algoritmo que não utiliza aprendizado por reforço: priorizar os pontos fáceis para a classificação. Juntamente com o texto, é possível entender a problemática, e entender o porquê da adição do aprendizado por reforço no processo.

## VI. TRABALHOS FUTUROS

Como trabalhos futuros propomos:

- Incluir também o conteúdo mais técnico na página, como os algoritmos escritos em pseudo-código e suas provas de convergências, para também ser possivelmente aprender profundamente sobre o assunto;
- Fazer uma análise mais aprofundada do aprendizado das pessoas que utilizam do site para aprender sobre o tema;
- Incluir mais visualizações específicas de Aprendizado por reforço. Vale ressaltar também que

## REFERENCES

- [1] J. Ye W. Deng B. Liu, Y. Guo. Selective pseudo-labeling with reinforcement learning for semi-supervised domain adaptation. 2021.
- [2] Jacob Hilton, Nick Cammarata, Shan Carter, Gabriel Goh, and Chris Olah. Understanding rl vision. *Distill*, 2020. <https://distill.pub/2020/understanding-rl-vision>.
- [3] R. Feitosa C. Almeida M. Schimalski D. Oliveira L. Rosa, C. Sothe. Multi-task fully convolutional network for tree species mapping in dense forests using small training hyperspectral data. *arXiv:2106.00799v2*, 2021.
- [4] M. Wilk M. Deisenroth, Y. Luo. A practical guide to gaussian processes. 2020.
- [5] F. Qi V. Ordonez P. Cascante-Bonilla, Y. Tan. Curriculum labeling: Revisiting pseudo-labeling for semi-supervised learning. *arXiv:2001.06001v2*, 2020.
- [6] Ben Shneiderman. The eyes have it: A task by data type taxonomy for information visualizations. 1996.